# Evaluación del asistente de Soporte TI

2026-10-25 18:52 UTC · 30 preguntas × 3 · LLM **gemma4:31b** · juez **gemma4:31b-cloud** · 90 consultas en 748 s · baseline gemma4 (Fase 8)

**Faithfulness**
0.739
Afirmaciones de la respuesta respaldadas por el contexto · objetivo ≥ 0.85 · n=24

**Answer relevancy**
0.760
La respuesta atiende a lo que se preguntó · objetivo ≥ 0.80 · n=24

**Context precision**
0.958
Los fragmentos útiles aparecen primero · objetivo ≥ 0.75 · n=24

**Context recall**
0.954
El contexto cubre la respuesta de referencia · objetivo ≥ 0.80 · n=24

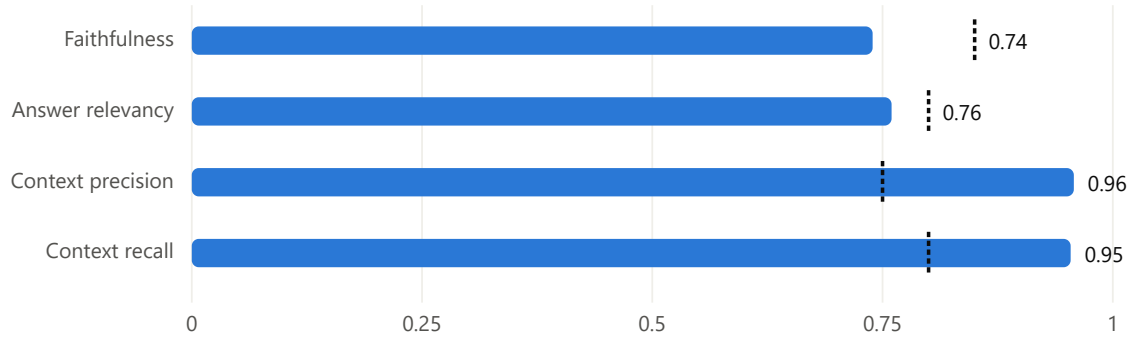
**Falsa abstención**
0.0 %
LLM 0.0 % · recuperación 0.0 %

**Abstención correcta**
100 %
Preguntas fuera de alcance en las que no inventa

**Recuperación**
100 %
Hit rate@k · MRR 1.000

**Latencia**
2.4 s
p50 · p95 5.2 s

## Métricas RAGAs




Media 0–1. La línea discontinua marca el objetivo de calidad. Faithfulness y answer relevancy se calculan sobre las respuestas emitidas; context precision y recall, sobre todas las preguntas con respuesta en el corpus (miden la recuperación aunque el modelo se abstenga).

## Resultado de cada consulta



Respondida: 72 Abstención correcta: 18

Preguntas con resultado distinto entre repeticiones: ninguna.

## Comparativa con ejecuciones anteriores

Primera ejecución registrada: no hay ejecuciones anteriores con las que comparar.

## Detalle por pregunta

| Id | Pregunta | Intentos | Rank doc. | Faithfulness | Answer relevancy | Context precision | Context recall |
|---|---|---|---|---|---|---|---|
| **GD-01** | ¿Qué hago si el batch de cierre diario se queda en estado RUNNING después de las 02:00?<br>▶ Respondida | ●●● | 1 | 1.000 | 0.514 | 0.700 | 0.400 |
| **GD-02** | ¿Qué significa el código CIE-305 en el log del batch de cierre?<br>▶ Respondida | ●●● | 1 | 0.400 | 0.812 | 1.000 | 1.000 |
| **GD-03** | ¿Por qué no se debe relanzar el batch de cierre desde el inicio?<br>▶ Respondida | ●●● | 1 | 0.875 | 0.715 | 1.000 | 1.000 |
| **GD-04** | ¿Cuándo hay que escalar al nivel 2 un fallo del batch de cierre?<br>▶ Respondida | ●●● | 1 | 0.800 | 0.513 | 1.000 | 1.000 |
| **GD-05** | Varios cajeros rechazan retiros con código 91, ¿qué significa y qué hago?<br>▶ Respondida | ●●● | 1 | 0.600 | 0.600 | 1.000 | 0.500 |
| **GD-06** | Si el código 91 aparece en un solo cajero, ¿cómo se gestiona?<br>▶ Respondida | ●●● | 1 | 0.857 | 0.627 | 1.000 | 1.000 |
| **GD-07** | ¿Qué lista de verificación se usa para activar el enlace de contingencia de los ATM?<br>▶ Respondida | ●●● | 1 | 0.500 | 0.791 | 1.000 | 1.000 |
| **GD-08** | ¿Qué pasa si el enlace de contingencia de cajeros no restablece el servicio?<br>▶ Respondida | ●●● | 1 | 0.750 | 0.671 | 1.000 | 1.000 |
| **GD-09** | ¿Qué indica un error HTTP 502 al iniciar sesión en la banca web?<br>▶ Respondida | ●●● | 1 | 0.600 | 0.863 | 1.000 | 1.000 |
| **GD-10** | Ante un 502 masivo en banca en línea, ¿cómo se reinician los nodos de autenticación?<br>▶ Respondida | ●●● | 1 | 1.000 | 0.694 | 1.000 | 1.000 |

| Id | Pregunta | Intentos | Rank doc. | Faithfulness | Answer relevancy | Context precision | Context recall |
|---|---|---|---|---|---|---|---|
| **GD-11** | Un cliente olvidó su contraseña de banca en línea, ¿puede TI Producción restablecerla?<br>▶ Respondida | ●●● | 1 | 0.500 | 0.798 | 0.833 | 1.000 |
| **GD-12** | ¿Qué hay que revisar en el monitoreo de aplicaciones cuando la banca web devuelve 502 a muchos usuarios?<br>▶ Respondida | ●●● | 1 | 0.875 | 0.576 | 1.000 | 1.000 |
| **GD-13** | ¿Cuántos custodios se necesitan para renovar el certificado del HSM?<br>▶ Respondida | ●●● | 1 | 0.800 | 0.836 | 1.000 | 1.000 |
| **GD-14** | ¿Con cuánta anticipación debe aprobarse la ventana de mantenimiento para renovar el certificado del HSM?<br>▶ Respondida | ●●● | 1 | 0.800 | 0.986 | 1.000 | 1.000 |
| **GD-15** | Después de importar el nuevo certificado del HSM, ¿qué servicio se reinicia?<br>▶ Respondida | ●●● | 1 | 0.667 | 0.899 | 1.000 | 1.000 |
| **GD-16** | ¿Qué hago si la transacción de prueba falla tras renovar el certificado TLS del HSM?<br>▶ Respondida | ●●● | 1 | 0.778 | 0.833 | 1.000 | 1.000 |
| **GD-17** | ¿Cuándo se dispara la alerta BD-LOCK-01?<br>▶ Respondida | ●●● | 1 | 0.750 | 0.709 | 1.000 | 1.000 |
| **GD-18** | ¿Puede el operador de TI Producción terminar una sesión de base de datos que causa un bloqueo?<br>▶ Respondida | ●●● | 1 | 1.000 | 0.896 | 0.917 | 1.000 |
| **GD-19** | ¿Cuándo se escala un bloqueo de base de datos al DBA de turno?<br>▶ Respondida | ●●● | 1 | 0.429 | 0.911 | 1.000 | 1.000 |
| **GD-20** | ¿Cuál es el tiempo de respuesta del DBA de turno | ●●● | 1 | 0.500 | 0.877 | 1.000 | 1.000 |

| Id | Pregunta | Intentos | Rank doc. | Faithfulness | Answer relevancy | Context precision | Context recall |
|---|---|---|---|---|---|---|---|
| | según la matriz de contacto?<br>▶ Respondida | | | | | | |
| **GD-21** | La VPN de guardia me rechaza con el error VPN-403, ¿qué hago?<br>▶ Respondida | ●●● | 1 | 0.857 | 0.854 | 0.700 | 1.000 |
| **GD-22** | ¿Qué perfil uso si aparece VPN-TIMEOUT?<br>▶ Respondida | ●●● | 1 | 0.571 | 0.629 | 1.000 | 1.000 |
| **GD-23** | ¿Puedo prestarle mi segundo factor de autenticación a otro guardia?<br>▶ Respondida | ●●● | 1 | 0.833 | 0.784 | 1.000 | 1.000 |
| **GD-24** | ¿Quién puede usar la VPN de guardia y cuándo se revoca el acceso?<br>▶ Respondida | ●●● | 1 | 1.000 | 0.848 | 0.833 | 1.000 |
| **GD-25** | ¿Cuál es el menú del comedor corporativo esta semana?<br>▶ Abstención correcta | ●●● | — | n/d | n/d | n/d | n/d |
| **GD-26** | ¿Cómo se configura la replicación de Kafka entre centros de datos?<br>▶ Abstención correcta | ●●● | — | n/d | n/d | n/d | n/d |
| **GD-27** | ¿Cuál es la tasa de interés vigente de los créditos hipotecarios?<br>▶ Abstención correcta | ●●● | — | n/d | n/d | n/d | n/d |
| **GD-28** | ¿Qué longitud de clave usa el certificado de firma de las transferencias SPI?<br>▶ Abstención correcta | ●●● | — | n/d | n/d | n/d | n/d |
| **GD-29** | ¿Cómo se restaura un backup de la base de datos del core bancario?<br>▶ Abstención correcta | ●●● | — | n/d | n/d | n/d | n/d |
| **GD-30** | ¿Cuántos días de vacaciones le corresponden a un operador de TI Producción?<br>▶ Abstención correcta | ●●● | — | n/d | n/d | n/d | n/d |

## Metodología

- Golden dataset: `tests/golden_dataset.json` — 24 preguntas con respuesta en el corpus y 6 fuera de alcance.
- Las consultas pasan por el api-gateway como llamada de sistema (sin RLS de área) con `include_contexts`, que devuelve los fragmentos completos entregados al LLM, también cuando se abstiene.
- **Falsa abstención del LLM**: el modelo se abstuvo aunque el documento esperado estaba en su contexto. **Por recuperación**: el documento esperado no llegó al contexto (fallo del retriever/reranker).
- Juez RAGAs: gemma4:31b-cloud con temperatura 0; embeddings sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2. Usar el mismo modelo como generador y juez introduce un sesgo de autoevaluación; para resultados definitivos conviene un juez distinto (`--judge-model`, `--judge-base-url`).