Evaluación del asistente de Soporte TI

2026-10-26 00:45 UTC · 36 preguntas × 3 · LLM **gemma4:31b** · juez **gemma4:31b-cloud** · 108 consultas en 829 s · chunking por secciones cortas

Faithfulness
0.752
Afirmaciones de la respuesta respaldadas por el contexto · objetivo ≥ 0.85 · n=30

Answer relevancy
0.748
La respuesta atiende a lo que se preguntó · objetivo ≥ 0.80 · n=30

Context precision
0.948
Los fragmentos útiles aparecen primero · objetivo ≥ 0.75 · n=30

Context recall
0.937
El contexto cubre la respuesta de referencia · objetivo ≥ 0.80 · n=30

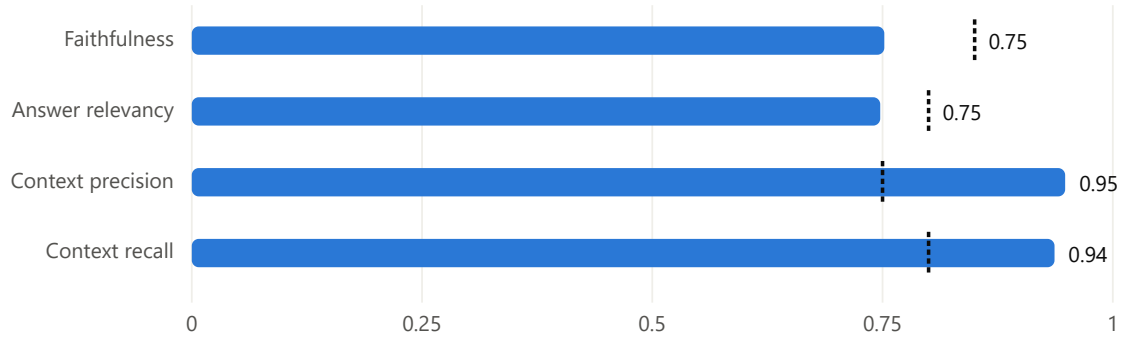
Falsa abstención
0.0 %
LLM 0.0 % · recuperación 0.0 %

Abstención correcta
100 %
Preguntas fuera de alcance en las que no inventa

Recuperación
100 %
Hit rate@k · MRR 1.000

Latencia
1.8 s
p50 · p95 2.9 s

Métricas RAGAs



Media 0–1. La línea discontinua marca el objetivo de calidad. Faithfulness y answer relevancy se calculan sobre las respuestas emitidas; context precision y recall, sobre todas las preguntas con respuesta en el corpus (miden la recuperación aunque el modelo se abstenga).

Resultado de cada consulta



● Respondida: 90 ● Abstención correcta: 18

Preguntas con resultado distinto entre repeticiones: ninguna.

Comparativa con ejecuciones anteriores

Ejecución	Faithfulness	Answer relevancy	Context precision	Context recall	Falsa abstención	Abst. correcta	Hit rate	p50 (s)
Esta ejecución gemma4:31b chunking por secciones cortas	0.752	0.748	0.948	0.937	0 %	100 %	100 %	1.8
2026-10-25 18:52 gemma4:31b baseline gemma4 (Fase 8)	0.739 ▲	0.760 ▼	0.958 ▼	0.954 ▼	0 %	100 %	100 %	2.4

▲/▼: la ejecución actual mejora/empeora respecto a esa fila.

Detalle por pregunta

Id	Pregunta	Intentos	Rank doc.	Faithfulness	Answer relevancy	Context precision	Context recall
GD-01	¿Qué hago si el batch de cierre diario se queda en estado RUNNING después de las 02:00? ▶ Respondida	●●●	1	0.625	0.649	0.700	0.600
GD-02	¿Qué significa el código CIE-305 en el log del batch de cierre? ▶ Respondida	●●●	1	0.833	0.749	1.000	1.000
GD-03	¿Por qué no se debe relanzar el batch de cierre desde el inicio? ▶ Respondida	●●●	1	0.857	0.694	1.000	1.000
GD-04	¿Cuándo hay que escalar al nivel 2 un fallo del batch de cierre? ▶ Respondida	●●●	1	0.800	0.498	1.000	1.000
GD-05	Varios cajeros rechazan retiros con código 91, ¿qué significa y qué hago? ▶ Respondida	●●●	1	0.667	0.600	1.000	0.500
GD-06	Si el código 91 aparece en un solo cajero, ¿cómo se gestiona? ▶ Respondida	●●●	1	0.667	0.503	1.000	1.000
GD-07	¿Qué lista de verificación se usa para activar el enlace de contingencia de los ATM? ▶ Respondida	●●●	1	0.500	0.788	1.000	1.000
GD-08	¿Qué pasa si el enlace de contingencia de cajeros no restablece el servicio? ▶ Respondida	●●●	1	0.875	0.680	1.000	1.000
GD-09	¿Qué indica un error HTTP 502 al iniciar sesión en la banca web? ▶ Respondida	●●●	1	0.600	0.875	1.000	1.000
GD-10	Ante un 502 masivo en banca en línea, ¿cómo se reinician los nodos de autenticación? ▶ Respondida	●●●	1	1.000	0.694	1.000	1.000

Id	Pregunta	Intentos	Rank doc.	Faithfulness	Answer relevancy	Context precision	Context recall
GD-11	Un cliente olvidó su contraseña de banca en línea, ¿puede TI Producción restablecerla? ▶ Respondida	●●●	1	0.714	0.764	1.000	1.000
GD-12	¿Qué hay que revisar en el monitoreo de aplicaciones cuando la banca web devuelve 502 a muchos usuarios? ▶ Respondida	●●●	1	0.875	0.588	1.000	1.000
GD-13	¿Cuántos custodios se necesitan para renovar el certificado del HSM? ▶ Respondida	●●●	1	0.600	0.840	1.000	1.000
GD-14	¿Con cuánta anticipación debe aprobarse la ventana de mantenimiento para renovar el certificado del HSM? ▶ Respondida	●●●	1	0.800	0.986	1.000	1.000
GD-15	Después de importar el nuevo certificado del HSM, ¿qué servicio se reinicia? ▶ Respondida	●●●	1	0.667	0.881	1.000	1.000
GD-16	¿Qué hago si la transacción de prueba falla tras renovar el certificado TLS del HSM? ▶ Respondida	●●●	1	0.750	0.923	1.000	1.000
GD-17	¿Cuándo se dispara la alerta BD-LOCK-01? ▶ Respondida	●●●	1	0.500	0.656	1.000	1.000
GD-18	¿Puede el operador de TI Producción terminar una sesión de base de datos que causa un bloqueo? ▶ Respondida	●●●	1	0.556	0.896	1.000	1.000
GD-19	¿Cuándo se escala un bloqueo de base de datos al DBA de turno? ▶ Respondida	●●●	1	1.000	0.899	1.000	1.000
GD-20	¿Cuál es el tiempo de respuesta del DBA de turno	●●●	1	0.750	0.992	1.000	1.000

Id	Pregunta	Intentos	Rank doc.	Faithfulness	Answer relevancy	Context precision	Context recall
	según la matriz de contacto? ▶ Respondida						
GD-21	La VPN de guardia me rechaza con el error VPN-403, ¿qué hago? ▶ Respondida	●●●	1	0.857	0.900	1.000	1.000
GD-22	¿Qué perfil uso si aparece VPN-TIMEOUT? ▶ Respondida	●●●	1	0.857	0.630	1.000	1.000
GD-23	¿Puedo prestarle mi segundo factor de autenticación a otro guardia? ▶ Respondida	●●●	1	0.833	0.774	1.000	1.000
GD-24	¿Quién puede usar la VPN de guardia y cuándo se revoca el acceso? ▶ Respondida	●●●	1	1.000	0.921	1.000	1.000
GD-25	¿Cuál es el menú del comedor corporativo esta semana? ▶ Abstención correcta	●●●	—	n/d	n/d	n/d	n/d
GD-26	¿Cómo se configura la replicación de Kafka entre centros de datos? ▶ Abstención correcta	●●●	—	n/d	n/d	n/d	n/d
GD-27	¿Cuál es la tasa de interés vigente de los créditos hipotecarios? ▶ Abstención correcta	●●●	—	n/d	n/d	n/d	n/d
GD-28	¿Qué longitud de clave usa el certificado de firma de las transferencias SPI? ▶ Abstención correcta	●●●	—	n/d	n/d	n/d	n/d
GD-29	¿Cómo se restaura un backup de la base de datos del core bancario? ▶ Abstención correcta	●●●	—	n/d	n/d	n/d	n/d
GD-30	¿Cuántos días de vacaciones le corresponden a un operador de TI Producción? ▶ Abstención correcta	●●●	—	n/d	n/d	n/d	n/d

Id	Pregunta	Intentos	Rank doc.	Faithfulness	Answer relevancy	Context precision	Context recall
GD-31	El panel de monitoreo muestra la alerta BD-LOCK-01 sobre la tabla de movimientos, ¿qué acción debo tomar? ▶ Respondida	●●●	1	0.667	0.528	1.000	0.500
GD-32	El log del job de cierre muestra el código CIE-201, ¿qué acción debo tomar? ▶ Respondida	●●●	1	0.667	0.711	0.750	1.000
GD-33	Los cajeros de varias agencias rechazan los retiros con el código 91, ¿qué acción debo tomar? ▶ Respondida	●●●	1	0.625	0.597	0.000	0.500
GD-34	El balanceador devuelve HTTP 502 a todos los usuarios de la banca web después del despliegue, ¿qué acción debo tomar? ▶ Respondida	●●●	1	0.875	0.659	1.000	1.000
GD-35	La VPN de guardia muestra VPN-TIMEOUT con ambos perfiles, ¿qué acción debo tomar? ▶ Respondida	●●●	1	0.667	0.713	1.000	1.000
GD-36	La transacción de prueba falla después de importar el nuevo certificado del HSM, ¿qué acción debo tomar? ▶ Respondida	●●●	1	0.875	0.837	1.000	1.000

Metodología

- Golden dataset: `tests/golden_dataset.json` — 30 preguntas con respuesta en el corpus y 6 fuera de alcance.
- Las consultas pasan por el api-gateway como llamada de sistema (sin RLS de área) con `include_contexts`, que devuelve los fragmentos completos entregados al LLM, también cuando se abstiene.
- **Falsa abstención del LLM**: el modelo se abstuvo aunque el documento esperado estaba en su contexto. **Por recuperación**: el documento esperado no llegó al contexto (fallo del retriever/reranker).

- Juez RAGAs: gemma4:31b-cloud con temperatura 0; embeddings sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2. Usar el mismo modelo como generador y juez introduce un sesgo de autoevaluación; para resultados definitivos conviene un juez distinto (`--judge-model`, `--judge-base-url`).